

# Sistema de recomendação de filme baseado no perfil do usuário

Enrico Najjar Galdeano, Gabriel Shihao Chen Yin, Samuel Lopes Pereira

Faculdade de Computação e Informática (FCI)  
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10402924, 10408981, [10403767](mailto:10403767@mackenzista.com.br)}@mackenzista.com.br

Link Github: <https://github.com/Enrico104029/Projeto-IA-.git>

Link do video : <https://youtu.be/gaJOpiDZog?si=2qL3cG24XFjqSAoV>

**Resumo.** O objetivo do projeto é o desenvolvimento de um sistema de recomendações de filmes personalizado que usa como base o estudo de K-Nearest Neighbors (KNN) (GEEKSFORGEES, 2017). O processo consiste em analisar o perfil do usuário com base em suas preferências de gêneros e autores, na intenção de facilitar a escolha dos conteúdos disponíveis nas principais plataformas de streaming. A proposta se justifica dada a dificuldade que os usuários encontram ao escolher um título disponível, mesmo sabendo quais são suas preferências. Serão usadas para o desenvolvimento do sistema técnicas de aprendizado de máquina, que serão responsáveis pelo algoritmo de indicação assertivo aos conteúdos relevantes por perfil.

## 1. Introdução

### a. Contextualização

Com o crescimento acelerado das plataformas de *streaming*, o consumo de filmes e séries aumentou significativamente nos últimos anos (SOUZA; BARTH, 2024). Contudo, a grande quantidade de títulos disponíveis pode gerar indecisão e frustração nos usuários, que gastam tempo excessivo na busca por conteúdos de seu interesse. Nesse cenário, sistemas de recomendação inteligentes surgem como ferramentas essenciais para personalizar a experiência do usuário.

### b. Justificativa

A justificativa para o desenvolvimento deste projeto está relacionada à necessidade de soluções que otimizem o processo de escolha de filmes e ampliem a satisfação do consumidor. Ao empregar técnicas de inteligência artificial, é possível capturar de maneira mais precisa as relações entre itens, oferecendo recomendações mais adequadas em comparação com métodos tradicionais. Além disso, o crescimento do mercado de streaming reforça a importância de mecanismos inovadores e escaláveis para melhorar a experiência do usuário.

### c. Objetivo

O objetivo principal do projeto foi desenvolver um sistema de recomendação de filmes baseado em K-Nearest Neighbors (KNN), capaz de analisar as características dos filmes e indicar conteúdos similares. Como objetivo secundário, avaliou-se a eficiência do modelo no conjunto de dados TMDb 5000, verificando a acurácia e a relevância das recomendações geradas.

### d. Opção do projeto e Justificativa Tecnológica

O projeto se enquadrava na área de Aprendizado de Máquina, mais especificamente na subárea de filtragem baseada em conteúdo, utilizando o algoritmo **K-Nearest Neighbors (KNN)** para encontrar a similaridade entre os filmes. A escolha dessa abordagem deveu-se ao fato de que ela é um método simples e eficaz para encontrar itens com características semelhantes em um espaço vetorial. O KNN permitiu explorar de forma eficiente essas relações, possibilitando a geração de recomendações personalizadas com alta precisão através do cálculo da distância do cosseno.

## 2. Fundamentação Teórica

Os sistemas de recomendação podem ser classificados em três tipos principais: baseados em conteúdo, colaborativos e híbridos (ISINKAYEVA; ISINKAYEV, 2021). O sistema proposto utilizou uma abordagem baseada em conteúdo, que se concentra em recomendar itens que são semelhantes àqueles que o usuário demonstrou interesse no passado.

Neste projeto, o algoritmo K-Nearest Neighbors (KNN) foi a técnica principal. O KNN é um método não-paramétrico usado para classificação e regressão. Ele funciona encontrando os "k" vizinhos mais próximos de um ponto de dados e fazendo uma previsão com base neles. No nosso caso, o KNN foi usado para encontrar filmes que fossem os mais "próximos" às características do filme de interesse. A biblioteca *scikit-learn* foi utilizada para a implementação do KNN, enquanto o dataset TMDb 5000 forneceu a base de dados.

## 3. Descrição do Problema

O problema central identificado é a dificuldade que usuários enfrentam para encontrar conteúdos que atendam plenamente aos seus interesses em meio à grande oferta de títulos em plataformas de *streaming*. Esse excesso de opções pode gerar indecisão, perda de tempo e frustração, um fenômeno conhecido como o *Paradoxo da Escolha* (SCHWARTZ, 2004). Métodos tradicionais de recomendação, como filtros simples ou listas genéricas, não são suficientes para capturar a complexidade das preferências individuais. Dessa forma, enxergou-se necessária uma abordagem mais sofisticada, que considerasse as características intrínsecas dos filmes para oferecer recomendações precisas.

## 4. Ética na Inteligência Artificial

O uso de inteligência artificial em sistemas de recomendação envolve questões éticas importantes. Um dos principais desafios é evitar a criação de bolhas de filtro, em que o usuário é exposto apenas a conteúdos semelhantes aos já consumidos, reduzindo a diversidade cultural. Outro aspecto relevante é a transparência: o usuário deve compreender que as recomendações são geradas por algoritmos e que podem conter vieses presentes nos dados de treinamento. Além disso, é necessário garantir a privacidade e a segurança dos dados, utilizando datasets anonimizados. No desenvolvimento desta solução, a responsabilidade recaiu sobre garantir que o sistema não discriminasse e respeitasse a diversidade de interesses.

## 5. Dataset e Análise Exploratória

**5.1. Origem e Tratamento** A origem do dataset utilizado neste projeto foi a TMDb (The Movie Database). Foram utilizados dois arquivos de dados públicos: `tmdb_5000_movies.csv` e `tmdb_5000_credits.csv`. Juntos, eles reuniram informações sobre aproximadamente 5.000 filmes.

No desenvolvimento, realizou-se a integração (*merge*) destes dois arquivos. As colunas irrelevantes para a similaridade de conteúdo, como *homepage* e *production\_companies*, foram removidas. Colunas complexas como *genres* e *cast*, que estavam em formato JSON, foram processadas (*parsed*) para listas Python utilizáveis.

**5.2. Análise Exploratória de Dados** A análise estatística permitiu compreender a distribuição dos dados antes da modelagem.

- **Avaliações:** A média de votos (*vote\_average*) foi de aproximadamente 6.09, com uma distribuição normal, indicando uma base equilibrada.
- **Gêneros:** Observou-se que gêneros como "Drama", "Comedy" e "Thriller" eram os mais frequentes, o que foi considerado na modelagem para evitar viés de popularidade.




Figura 1 – Histograma da distribuição das notas médias dos filmes, Fonte: Elaborado pelos autores (2025)




Figura 2 – Frequência dos principais gêneros cinematográficos no dataset, Fonte: Elaborado pelos autores (2025).

## 6. Metodologia

A metodologia aplicada seguiu as etapas de Engenharia de *Aprendizado de Máquina*:

1. **Pré-processamento:** Limpeza de dados nulos em campos críticos e extração do ano de lançamento (*release\_year*) a partir da data completa.
2. **Engenharia de Atributos:**
  - **Gêneros (One-Hot Encoding):** A coluna de gêneros foi transformada em vetores binários (0 ou 1) utilizando a técnica de *One-Hot Encoding*. Isso criou uma representação vetorial onde cada gênero único se tornou uma dimensão, permitindo o cálculo matemático de similaridade.
  - **Normalização:** As variáveis numéricas *vote\_average* (0-10) e *release\_year* foram normalizadas para a escala [0, 1] usando a técnica Min-Max. Isso garantiu que a dimensão "Ano" não dominasse o cálculo de distância sobre a dimensão "Gênero".
3. **Seleção de Atributos:** O modelo final utilizou os atributos de **Gêneros**, **Nota Média** e **Ano de Lançamento**. O elenco (*cast*) foi analisado mas não incluído na matriz final devido à alta dimensionalidade.
4. **Modelo KNN:** Implementação do algoritmo `NearestNeighbors` da biblioteca *scikit-learn* com a métrica de **cosseno** (*cosine similarity*), configurada para buscar os vizinhos mais próximos no espaço vetorial criado.

## 7. Resultados e Conclusão

O sistema desenvolvido demonstrou capacidade de gerar recomendações consistentes e semanticamente relevantes.

**Resultados Obtidos:** Em testes realizados, o modelo apresentou alta precisão qualitativa:

- Para o filme *Avatar* (Ação/Ficção Científica), o sistema recomendou títulos como *Jupiter Ascending* e *The Wolverine*, mantendo a coerência de gênero e estilo visual.
- Para *Titanic* (Drama/Romance), as sugestões incluíram *The Phantom of the Opera* e *Cruel Intentions*, validando a capacidade do modelo de capturar a combinação de romance com elementos dramáticos.

**Conclusão:** O projeto atingiu o objetivo de criar um motor de recomendação funcional baseado em conteúdo. A utilização do algoritmo KNN com distância de cosseno, aliada ao tratamento de dados via *One-Hot Encoding* e normalização, provou-se uma estratégia eficiente para resolver o problema de descoberta de conteúdo sem a

necessidade de histórico de usuário (*Cold Start*), entregando sugestões pertinentes baseadas apenas nas características intrínsecas dos filmes.

## 8. Referências Bibliográficas

GEEKSFORGEEEKS. **K-Nearest Neighbor(KNN) Algorithm**. [S.l.], 2017. Disponível em: <https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbours/>. Acesso em: set. 2025.

ISINKAYEVA, G.; ISINKAYEV, M. The fundamentals of recommendation systems: collaborative filtering, content-based filtering, and hybrid methods. In: **INTERNATIONAL CONFERENCE ON INFORMATION TECHNOLOGY AND APPLICATIONS (ICITA)**. [S.l.: s.n.], 2021.

SCHWARTZ, Barry. **O paradoxo da escolha: Por que mais é menos**. Tradução de Bárbara Bentes. São Paulo: A Girafa, 2004.

SOUZA, D.; BARTH, M. Impactos no consumo de conteúdo audiovisual em plataformas de streaming durante a pandemia de Covid-19. **Revista UNINTER de Comunicação**, Curitiba, v. 10, n. 17, p. 69–80, 2024. Disponível em: <https://www.revistasuninter.com/revistacomunicacao/index.php/revista/article/view/886>. Acesso em: 06 set. 2025.

VAZ, A. L. **One-hot-encoding, o que é?** Medium, [S.d.]. Disponível em: <https://arthurlambletvaz.medium.com/one-hot-encoding-o-que-%C3%A9-cd2e8d302ae0>. Acesso em: set. 2025.